הרצאה 6: חישוב תת הסדרה המשותפת הארוכה ביותר

להלן תיאור הבעיה:

קלט

שתי סדרות תווים X ו- Y

פלט

תת סדרה משותפת ל-X ול-Y שארכה מרבי.

(Longest Common Subsequence (LCS).

נסמן את תת הסדרה המשותפת ב-$LCS(X,Y)$.

שימו לב

יתכנו מספר תת סדרות מכסימליות .

© כל הזכויות שמורות לפרופסור עמוס ישראלי

תזכורת

נתבונן בסדרה $s=(1,2,4,3,2,1,5)$

הסדרה $s_1=(1,2,3,5)$

היא תת סדרה של הסדרה s.

הסדרה $s_2=(1,5,2,4)$ אינה תת סדרה של s מפני ש - s_1 אינה שומרת על סדר האיברים ב-s.

דוגמה ל-LCS

$$X=(a,c,b,d,f)$$

$$Y=(b,c,d,a,f,g)$$

$$LCS1=(b,d,f)$$

$$LCS2=(c,d,f)$$

© כל הזכויות שמורות לפרופסור עמוס ישראלי

הגדרה 6.1:

1. תהי $X = (x_1,...,x_n)$ סדרה.

   הרישה ה-i של X, $0 \le i \le n$,

   היא תת הסדרה המכילה את i

   התווים הראשונים של X, כלומר

   $(x_1,...,x_i)$.

   נסמן $X_i = (x_1,...,x_i)$.

2. **הסדרה הריקה** היא הסדרה

   שאינה מכילה אפילו תו אחד.

   נסמן את הסדרה הריקה ב-Λ.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

הכנות לאלגוריתם רקורסיבי

שתי הלמות הבאות ישמשו באלגוריתם הרקורסיבי לחישוב LCS שנפתח בהמשך.

הבנה 6.2 - תנאי קצה

תהי Y סדרה כלשהי אזי תת הסדרה המשותפת המרבית של Y עם הסדרה הריקה שווה לסדרה הריקה, כלומר

$$LCS(Y,\Lambda) = LCS(\Lambda,Y) = \Lambda$$

הוכחה

לכל זוג סדרות תווים X ו-Y האורך של כל תת סדרה המכסימלית של X ו-Y **קטן או שווה** מאורך כל אחת מסדרות הקלט.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

למה 6.3: קיצור הקלט

תהיינה $X = (x_1,\ldots,x_n)$

ו-$Y = (y_1,\ldots,y_m)$ סדרות תווים.

אם $x_n = y_m$, אזי

$$LCS(X,Y) = LCS(X_{n-1},Y_{m-1}) \circ x_n$$

כלומר: אם התו האחרון של X, שווה לתו האחרון של Y, אזי כל LCS של X ו-Y מתקבלת על ידי שרשור של אחת מן ה-LCS של X_{n-1} ו-Y_{m-1} עם התו המשותף האחרון x_n.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

דוגמא

$$X = (a, c, b, d, f)$$

$$Y = (b, c, d, a, f)$$

$$LCS(X, Y) = LCS(X_4, Y_4)$$

$$= (c, d, f)$$

הוכחה

תהי $Z = (z_1, \ldots, z_k)$ תת סדרה

משותפת מרבית של X ו-Y. נניח

בשלילה כי $z_k \neq x_n$.

הסדרה $Z \circ x_n$ היא תת סדרה

משותפת של X ושל Y

שאורכה $k+1$ - **סתירה.** **מש"ל**

© כל הזכויות שמורות לפרופסור עמוס ישראלי

למה 6.4: קיצור הקלט (2)

יהיו X ו-Y סדרות. אם $x_n \neq y_m$, אזי

$$LCS(X,Y) =$$

$$LCS(X,Y_{m-1}) \,||\, LCS(X_{n-1},Y)$$

כלומר: התו האחרון **באחת הסדרות הקלט (לא ידוע מאיזה סדרה)** בלי לפגוע ב-LCS.

דוגמא

$$X = (c,b,d,g,f)$$

$$Y = (b,c,d,g)$$

אפשר להוריד את התו האחרון מן הסדרה X ולקבל

$$LCS(X,Y) =$$

$$LCS(X_4,Y) = (c,d,g)$$

© כל הזכויות שמורות לפרופסור עמוס ישראלי

הוכחה

אם התו האחרון באחת הסדרות משתתף ב-LCS, הוא חייב להיות במקום האחרון של ה-LCS. במקום זה יכול להיות תו אחד בלבד. לכן, אפשר להוריד את התו האחרון בסדרה השניה. **מש״ל**

שימו לב:

אם שני התווים האחרונים אינם משתתפים ב-LCS, בוודאי אפשר להוריד כל אחד מהם.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

אלגוריתם רקורסיבי לחישוב אורך *LCS*

בהינתן שתי סדרות X ו-Y, נחשב תחילה את אורך תת הסדרה המרבית. באיור 6.5 מוצג האלגוריתם הרקורסיבי $RecLen\left(X_i, Y_j\right)$ לחישוב אורך ה-LCS של הרישות X_i ו-Y_j.

אורך תת הסדרה המרבית של X ושל Y יתקבל על ידי הקריאה $RecLen\left(X_n, Y_m\right)$.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

קוד האלגוריתם

```
RecLen(X_i, Y_j)
    if (i = 0) return 0 end if
    if (j = 0) return 0 end if
    if (x_i = y_j)
        return RecLen(X_{i-1}, Y_{j-1}) + 1
    else return
            max{RecLen(X_{i-1}, Y_j),
                RecLen(X_i, Y_{j-1})}
    end if
end(RecLen)
```

איור 6.5: אלגוריתם *RecLen*

נכונות האלגוריתם נובעת מיידית מלמות 6.2, 6.3 ו-6.4.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

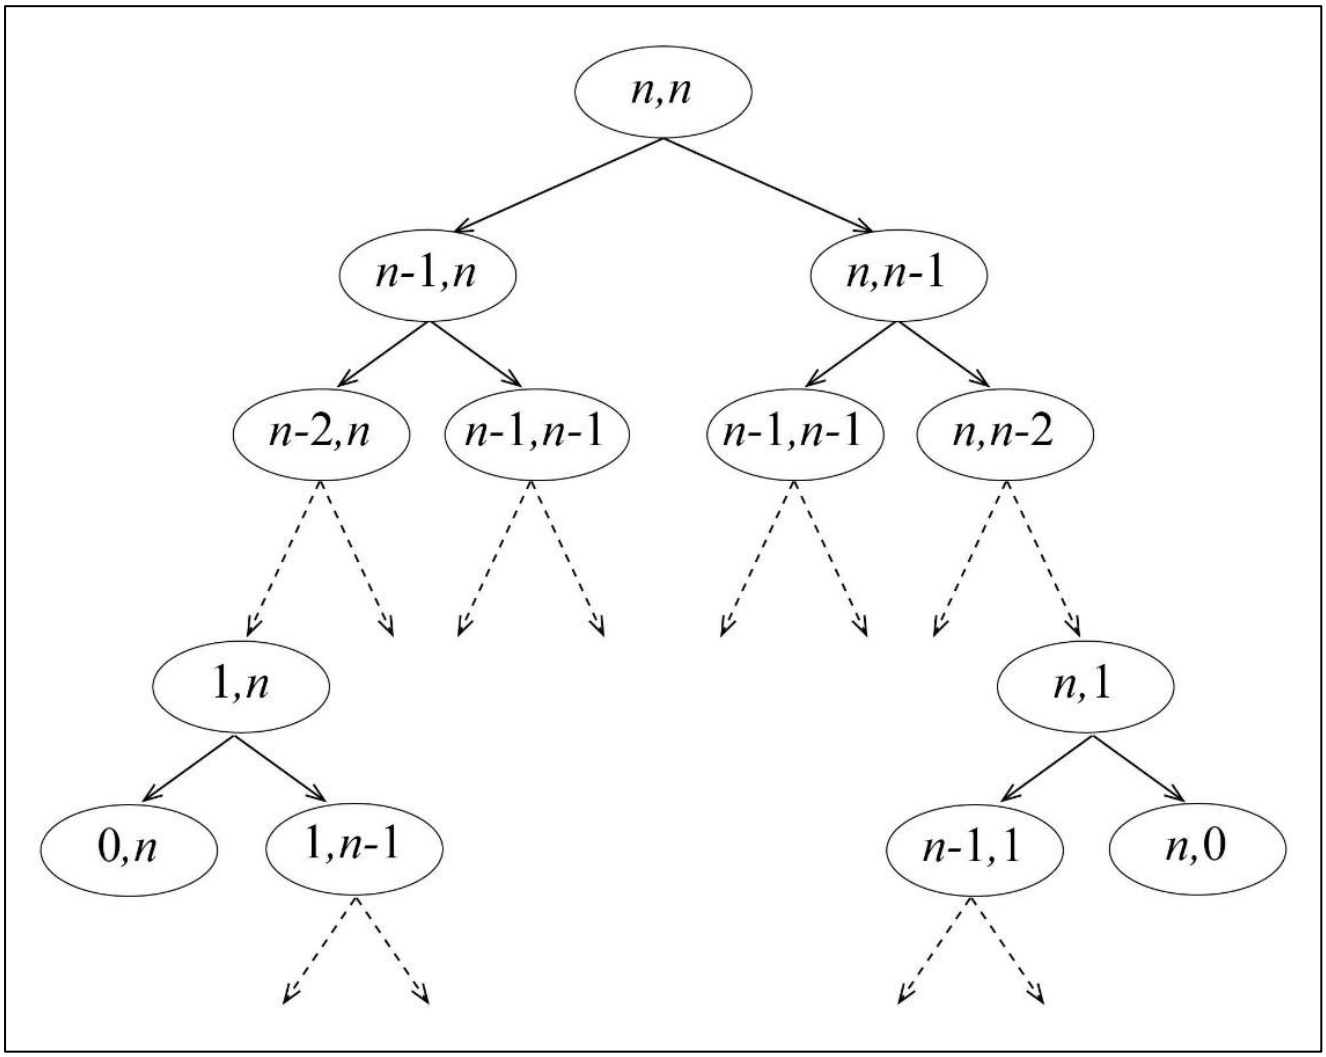
סיבוכיות האלגוריתם

כדי להעריך את סיבוכיות השיטה *RecLen* נניח ש-*RecLen* מתבצעת עם שתי סדרות אשר מספר התווים בכל אחת מהן הוא n ואין להן אף תו משותף. במצב זה כל קריאה של *RecLen* מבצעת **שתי קריאות רקורסיביות**. מכאן נובע שעץ הרקורסיה הוא מלא.

באיור 6.6 מתואר חלקו העליון של עץ הרקורסיה בביצוע זה. כל צומת בעץ הרקורסיה מייצג קריאה רקורסיבית לשיטה *RecLen*. צרוף הארגומנטים לכל קריאה כזו הוא $\left(X_i, Y_j\right)$ כאשר

© כל הזכויות שמורות לפרופסור עמוס ישראלי

$0 \le i, j \le n$ (כי הנחנו $n = m$). כדי לשמור על בהירות השרטוט בחרנו להציג בכל צומת של עץ הרקורסיה רק את ערכי i ו-j.



איור 6.6: עץ הרקורסיה של *RecLen*

© כל הזכויות שמורות לפרופסור עמוס ישראלי

סיבוכיות האלגוריתם (המשך)

מספר הרמות בתת עץ הרקורסיה המוצג באיור 6.6 הוא $n+1$ וגובהו של תת העץ הוא n. מכאן – מספר הקריאות הרקורסיביות המיוצגות בתת העץ הזה הוא $2^{n+1}-1$ כלומר סיבוכיות אלגוריתם $RecLen$ היא מעריכית.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

אלגוריתם בשיטת התכנון הדינמי

כאשר אורכיהן של X ו-Y, הם n ו-m, מספר צירופי הפרמטרים השונים ל-$RecLen$, כולל הסדרה הריקה, הוא $(n+1)\cdot(m+1)$. מכאן נובע כי אפשר להשתמש בשיטת התכנון הדינמי כדי לקבל אלגוריתם בסיבוכיות פולינומית. אלגוריתם $DPLCS$ מחשב את הערכים המוחזרים על ידי כל קריאה ל-$RecLen$ ומאחסן את הערכים המוחזרים מכל אחת מן הקריאות, במערך דו ממדי, Len, אשר משמש כטבלת מעקב. ממדי המערך Len הם $(n+1)\times(m+1)$ עם האינדקסים $0...n$, ו-$0...m$.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

דוגמא

באיור 6.7 מוצג המערך Len המשמש לביצוע $DPLCS$ עם הסדרות

$$X \equiv \left(c,\overline{a},b,\overline{c},e,a,\underline{b},a,\overline{d},\overline{a},c,\overline{d},f\right)$$

$$Y = \left(\overline{a},\overline{c},\overline{d},\underline{b},\overline{a},e,\overline{d}\right)$$

במצבו לפני ביצוע האלגוריתם.

לכל $1 \le i \le n$, העמודה ה-i של Len מסומנת ב-x_i. לכל $1 \le j \le m$, השורה ה-j של Len, מסומנת ב-y_j.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

טבלת המעקב - *Len* המערך

	Λ	*c*	*a*	*b*	*c*	*e*	*a*	*b*	*f*	*d*	*a*	*c*	*d*	*F*
Λ														
a														
c														
d														
b														
a														
e														
d														

איור 6.7: המערך *Len*

קוד אלגוריתם *DPLCS* מוצג באיור 6.8.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

אלגוריתם *DPLCS* - גרסה פשוטה

```
DPLCS(X,Y)
  for j ← 0 to m  Len[0, j] ← 0 end for
  for i ← 0 to n  Len[i,0] ← 0 end for

   for i ← 1 to m
      for j ← 1 to n
        if (x_i = y_j)
           (Len[i, j] ← Len[i −1, j −1]+1)
         else
           Len[i, j] ← max{Len[i −1, j], Len[i, j −1]}
        end if
      end for
  end for
  return(Len[n,m])
```

איור 6.8: אלגוריתם *DPLCS*

© כל הזכויות שמורות לפרופסור עמוס ישראלי

תיאור האלגוריתם

אלגוריתם *DPLCS*, בגרסה הפשוטה, מקבל כקלט שתי סדרות תווים, *X*, ו-*Y*, מחשב את המערך *Len* ומחזיר את אורכה של תת סדרה מרבית משותפת לסדרות הקלט.

קלטי הקצה לאלגוריתם *RecLen* הם הקלטים בהם אחת מסדרות הקלט ריקה. הערך המוחזר עבור כל אחד מקלטים אלה הוא 0.

בהתאמה, אלגוריתם *DPLcs* נפתח באיפוס השורה הראשונה והעמודה הראשונה במערך *Len*. איברי השורה הראשונה מתקבלים מקלטי קצה

© כל הזכויות שמורות לפרופסור עמוס ישראלי

שצורתם (X_i, Λ) ואיברי העמודה הראשונה מתקבלים מקלטי קצה שצורתם (Λ, Y_j).

בתחילת האלגוריתם ערכי הקצה האלה מאוחסנים בשורה 0 ובעמודה 0 של המערך Len המתאימים למקרי הקצה.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

חישוב איברי המערך *Len* עבור קלטים שאינם קלטי קצה

כדי להבין את חישוב איברי המערך *Len* המכילים את הערכים המוחזרים על ידי אלגוריתם *RecLen* עבור קלטים שאינם מקרי קצה נתבונן בקטע הקוד מן השיטה *RecLen* המחשב את הערך המוחזר מן הקריאה

$$RecLen\left[X_i, Y_j\right]$$

if $\left(x_i = y_j\right)$ ***return*** $RecLen\left(X_{i-1}, Y_{j-1}\right)+1$

else *return*

$\max\{RecLen\left(X_{i-1}, Y_j\right),\ RecLen\left(X_i, Y_{j-1}\right)\}$

end if

איור 6.9

© כל הזכויות שמורות לפרופסור עמוס ישראלי

חישוב $RecLen(X_i, Y_j)$ כולל 3 קריאות רקורסיביות: $RecLen(X_{i-1}, Y_{j-1})$, $RecLen(X_{i-1}, Y_j)$ ו-$RecLen(X_i, Y_{j-1})$.

בדומה לכך, חישוב $Len(X_i, Y_j)$ משתמש ב-$Len(X_{i-1}, Y_{j-1})$, $Len(X_{i-1}, Y_j)$ ו-$Len(X_i, Y_{j-1})$.

האיבר היחיד שאפשר לחשב, לאחר חישוב ערכי הקצה, הוא $Len[1,1]$ תוך שימוש בערכי $Len[0,0]$, $Len[0,1]$ ו-$Len[1,0]$ שכבר חושבו.

בהמשך אפשר לחשב את כל איברי שורה 1 כאשר חישוב $Len[1,j]$

© כל הזכויות שמורות לפרופסור עמוס ישראלי

מסתמך על ערכי האיברים

$Len[0, j]$,$Len[0, j-1]$

ו-$Len[1, j-1]$.

לאחר השלמת שורה 1 האלגוריתם מחשב את איברי שורה 2 באופן דומה וכן הלאה.

בסיום האלגוריתם מתקיים: לכל

$0 \le i, j \le n$

$$Len[i, j] = RecLen(i, j)$$

© כל הזכויות שמורות לפרופסור עמוס ישראלי

המערך *Len* בסיום DPLCS

	Λ	*c*	*a*	*b*	*c*	*e*	*a*	*b*	*f*	*d*	*a*	*c*	*d*	*f*
Λ	0	0	0	0	0	0	0	0	0	0	0	0	0	0
a	0	0	1	1	1	1	1	1	1	1	1	1	1	1
c	0	1	1	1	2	2	2	2	2	2	2	2	2	2
d	0	1	1	1	2	2	2	2	2	3	3	3	3	3
b	0	1	1	2	2	2	2	3	3	3	3	3	3	3
a	0	1	2	2	2	2	2	3	3	3	4	4	4	4
e	0	1	2	2	2	3	3	3	3	3	4	4	4	4
d	0	1	2	2	2	3	3	3	3	4	4	4	5	5

איור 6.10: המערך *Len* בסיום האלגוריתם

© כל הזכויות שמורות לפרופסור עמוס ישראלי

תובנה 6.11

נניח שאלגוריתם $DPLCS$ מבוצע עם הסדרות X ו-Y ו יהי Len המערך ש-$DPLCS$ מחשב. לכל $1 \le i \le n$, ולכל $1 \le j \le m$, מתקיים: $Len[i,j]$, שווה לאורך של $LCS\left(X_i, Y_j\right)$. בפרט, אורך תת הסדרה המכסימלית מאוחסן באיבר $Len[m,n]$.

ההוכחה באינדוקציה על $i+j$, בהסתמך על למות 6.2-6.4 . **מש"ל**

© כל הזכויות שמורות לפרופסור עמוס ישראלי

סיבוכיות אלגוריתם $DPLCS$ היא $\Theta(n \cdot m)$.

באיור 6.12 שבשקף הבא מוצגת גרסה מחוזקת של אלגוריתם $DPLCS$ המאפשרת את חישוב ה-LCS עצמה. האלגוריתם המחוזק משתמש במערך $From$, גם הוא מסדר $n \times m$.

לכל $1 \leq i \leq n$ ולכל $1 \leq j \leq m$ באיבר $From[i, j]$ מאוחסן מצביע אל האיבר במערך $From$ המשתתף בחישוב האיבר $Len[i, j]$.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

```
DPLCS(X,Y)
    for j ← 0 to m; Len[0,j] ← 0; end for
    for i ← 1 to n; Len[i,0] ← 0; end for
    for i ← 1 to n
        for j ← 1 to m
            if (x_i = y_j)
                Len[i,j] ← Len[i−1,j−1]+1;
                From[i,j] ← "↖"
            else if (Len[i−1,j] ≥ Len[i,j−1])
                Len[i,j] ← Len[i−1,j];
                From[i,j] ← "↑"
            else
                Len[i,j] ← Len[i,j−1];
                From[i,j] ← "←"
            endif
        end for
    end for
    return ExtractLCS(From,X,Y)
end(DPLCS)
```

איור 6.12: אלגוריתם *DPLCS* המחוזק

© כל הזכויות שמורות לפרופסור עמוס ישראלי

דוגמא

נתבונן בסדרות

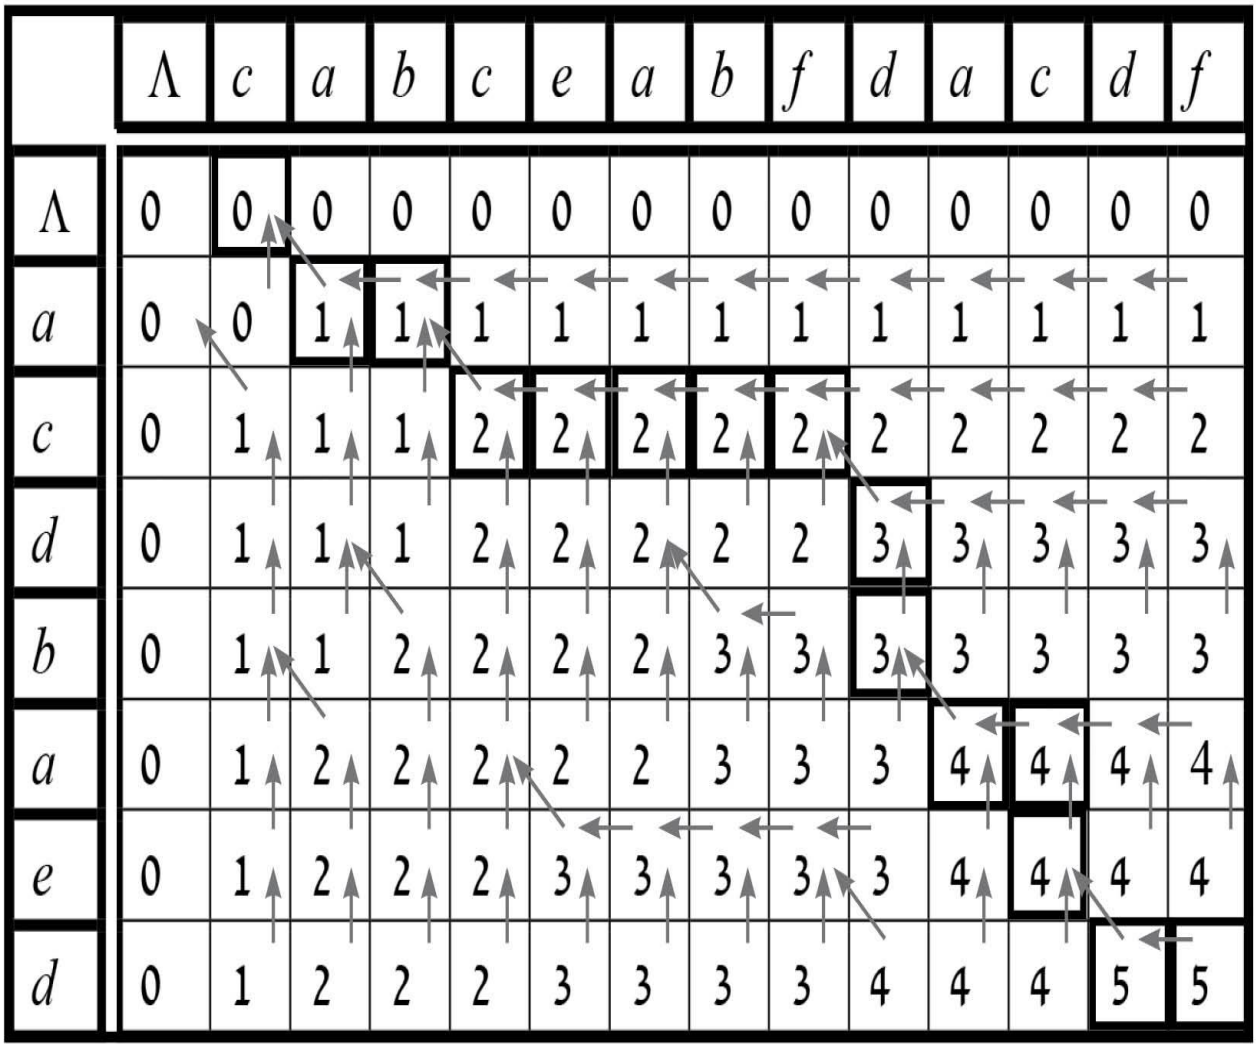
$$X \equiv \left(c,\bar{a},b,\bar{c},e,a,\underline{b},a,\bar{d},\bar{a},c,\bar{d},f\right)$$

$$Y = \left(\bar{a},\bar{c},\bar{d},\underline{b},\bar{a},e,\bar{d}\right)$$

לסדרות הנתונות קימות שתי תת סדרות משותפות מרביות: תת הסדרה המרבית הראשונה היא $\left(a,c,d,a,d\right)$ והיא מסומנת על ידי קו עליון מעל כל תו בשתי סדרות הקלט. אם נחליף את התו $\bar{d}$ ב-$\underline{b}$ נקבל את תת הסדרה המרבית השניה: $\left(a,c,b,a,d\right)$.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

באיור 6.13 המערכים *Len* ו-*From* מוצגים **ביחד**.



	Λ	*c*	*a*	*b*	*c*	*e*	*a*	*b*	*f*	*d*	*a*	*c*	*d*	*f*
Λ	0	0	0	0	0	0	0	0	0	0	0	0	0	0
a	0	0	1	1	1	1	1	1	1	1	1	1	1	1
c	0	1	1	1	2	2	2	2	2	2	2	2	2	2
d	0	1	1	1	2	2	2	2	2	3	3	3	3	3
b	0	1	1	2	2	2	2	3	3	3	3	3	3	3
a	0	1	2	2	2	2	2	3	3	3	4	4	4	4
e	0	1	2	2	2	3	3	3	3	3	4	4	4	4
d	0	1	2	2	2	3	3	3	3	4	4	4	5	5

איור 6.13: המערכים *Len*

(מספרים שלמים) ו-*From* (חיצים)

מוצגים ביחד

© כל הזכויות שמורות לפרופסור עמוס ישראלי

באיור 6.14 מוצגת השיטה *ExtractLCS* אשר מקבלת כקלט את המערך *From* ואת הסדרות X ו- Y ומחזירה אחת מן ה- *LCS* של X, ו-Y.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

```
ExtractLCS(From, X, Y)
    LCS ← Λ; (i, j) ← (n, m)
    while (i ≠ 0) ∨ (j ≠ 0)
        if (From[i, j] = "↖")
            LCS ← x_i ∘ LCS
            (i, j) ← (i − 1, j − 1)
        elseif (From[i, j] = "↑")
            (i, j) ← (i − 1, j)
        else \* From[i, j] = "←" *\
            (i, j) ← (i, j − 1)
        end if
    end while
    return(LCS)
end(ExtracLCS)
```

איור 6.14: השיטה *ExtractLCS*

© כל הזכויות שמורות לפרופסור עמוס ישראלי

השיטה *ExtractLCS* מקבלת כקלט את המערך *From* ואת הסדרות X ו-Y ומחשבת אחת מן ה- *LCS* של X ו-Y.

כדי לבנות אחת מן ה-*LCS*, השיטה *ExtractLCS* מסיירת מן המיקום (n,m) אל המיקום $(0,0)$ תוך שימוש במערך *From*. במהלך הסיור ה-*LCS* נבנית מן הסוף להתחלה. מיקום הסיור מאוחסן בזוג המשתנים (i,j) והסיפא של ה-*LCS* מאוחסנת במשתנה *LCS*.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

לפני תחילת הסיור מאתחלים:

- $LCS \leftarrow \Lambda$ ו-$(i,j) \leftarrow (n,m)$

הערכים m ו-n מתקבלים מן הסדרות X ו-Y.

בכל צעד, הסיור עובר מן המיקום (i,j) אל המיקום $From[i,j]$. אם המעבר הוא אלכסוני, כלומר אם $x_i = y_j$, התו x_i משורשר משמאל לרישה הנוכחית המאוכסנת במשתנה LCS.

הסיור מסתיים כאשר הוא מגיע אל השורה ה-0 או אל העמודה ה-0 ואז ערכה של ה-LCS נשלח לפלט.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

באיור 6.14, המסלול המתאים לתת הסדרה המשותפת (a,c,d,a,d), ואשר מחושב על ידי השיטה *ExtractLCS*, מוצג על ידי הדגשת איברי הטבלה השייכים למסלול זה. נכונות *ExtractLCS* נובעת מנכונות אלגוריתם *DPLCS*, ומלמות 6.2-6.4. סיבוכיות *ExtractLCS* היא $\Theta(n+m)$. סיבוכיות האלגוריתם המלא לחישוב תת הסדרה המרבית היא $\Theta(n \cdot m)$.

© כל הזכויות שמורות לפרופסור עמוס ישראלי

סיכום

בהרצאה זו הצגנו אלגוריתם יעיל לפתרון בעיית **תת הסדרה המכסימלית** תוך שימוש בתכנון דינמי.

© כל הזכויות שמורות לפרופסור עמוס ישראלי